

NOEMA

Documentation datée d'un régime post-exécutif de production intellectuelle

Charles Mordelet
Chercheur indépendant
`adm.charles@pm.me`

Juin 2026

Résumé

Quand l'exécution formelle devient délégable à des modèles qui dépassent l'opérateur sur des sous-domaines précis, un critère concurrent de compétence intellectuelle devient observable : il ne se mesure plus d'abord à l'exécution directe, mais à la conduite d'une chaîne d'exécution déléguée. Le phénomène n'est pas spéculatif : dans les environnements de production les plus avancés, des modèles servent déjà à entraîner, corriger et durcir des modèles plus puissants. Ce papier documente la forme que prend ce régime une fois dépouillé de son enveloppe institutionnelle de vérification : un opérateur non-exécutant formel produit des artefacts formellement falsifiables, en déléguant toute l'exécution à une topologie de modèles hétérogènes, temporellement tracée par des journaux d'intervention, et en ne retenant que les deux fonctions structurellement non délégables : spécifier l'intention, et détecter l'écart entre l'artefact obtenu et la part non sérialisée de cette intention. Comme ces modèles échouent silencieusement, la vérification formelle est elle aussi déléguée, à une cascade de sphères décorréliées dont le plancher d'erreur décroît avec leur diversité, jamais avec leur nombre ; l'erreur commune à toutes ne cède qu'à des sphères absentes du pipeline, ce qu'apporte l'exposition open-source. L'opérateur n'est donc pas un exécutant diminué mais une fonction architecturale : source du noéma, constructeur de la topologie, garant de la fidélité à l'intention, non de la vérité formelle.

Aucune supériorité générale n'est revendiquée. Deux asymétries locales le sont, car observables : la vitesse et le parallélisme de l'exécution déléguée, et son coût marginal de réplification face au coût de formation d'un exécutant humain. La thèse, elle, est structurelle et conditionnelle : dans la fenêtre où l'objet est exécutable par les modèles disponibles mais non entièrement sérialisable par l'opérateur, où les erreurs des modèles sont assez décorréliées et où l'artefact est exposé à la réfutation, l'orchestration peut devenir plus puissante qu'une exécution humaine isolée ; hors de cette fenêtre, elle ne s'applique pas. Une prédiction centrale (le plancher décroît avec la diversité des sphères, non avec le nombre de passes) a reçu un premier pilote daté multi-familles (annexe B), qui l'expose à réfutation et ne la réfute pas ; la garde de l'intention a reçu un premier pilote observationnel sur un projet industriel réel (annexe C). Ce papier n'est ni une preuve, ni un manifeste, ni une méthode validée : c'est la documentation datée d'un régime émergent, fixée au moment où il devient assez structuré pour être décrit, alors que les institutions évaluent encore avec les catégories du régime précédent.

Mots-clés : orchestration d'inférence distribuée, délégation formelle, défaillance silencieuse, plancher de corrélation inter-modèles, falsifiabilité, intention, déplacement de régime, intelligence post-exécutive.

Abstract

When formal execution becomes delegable to models that surpass the operator on specific subdomains, a competing criterion of intellectual competence becomes observable: it is no longer measured primarily by direct execution, but by the conduct of a delegated execution chain. The phenomenon is not speculative: in the most advanced production environments, models already serve to train, correct and harden more powerful models. This paper documents the form this regime takes once stripped of its institutional verification envelope: a formally non-executing operator produces formally falsifiable artifacts by delegating all execution to a topology of heterogeneous models, temporally traced through intervention logs, while retaining only the two structurally non-delegable functions: specifying the intention, and detecting the gap between the artifact obtained and the non-serialized part of that intention. Since these models fail silently, formal verification is itself delegated to a cascade of decorrelated spheres whose error floor decreases with their diversity, never with their number; the error common to all of them yields only to spheres absent from the pipeline, which is what open-source exposure provides. The operator is thus not a diminished executor but an architectural function: source of the noema, builder of the topology, guarantor of fidelity to the intention, not of formal truth.

No general superiority is claimed. Two local asymmetries are, because they are observable: the speed and parallelism of delegated execution, and its marginal replication cost against the training cost of a human executor. The thesis itself is structural and conditional: within the window where the object is executable by available models yet not fully serializable by the operator, where model errors are sufficiently decorrelated and the artifact is exposed to refutation, orchestration can become more powerful than isolated human execution; outside this window, it does not apply. A central prediction (the floor decreases with sphere diversity, not with the number of passes) has received a first dated multi-family pilot (Appendix B), which exposes it to refutation and does not refute it; the guarding of intention has received a first observational pilot on a real industrial project (Appendix C). This paper is neither a proof, nor a manifesto, nor a validated method: it is the dated documentation of an emerging regime, fixed at the moment it becomes structured enough to be described, while institutions still evaluate with the categories of the previous regime.

Keywords: distributed inference orchestration, formal delegation, silent failure, inter-model correlation floor, falsifiability, intention, regime shift, post-executive intelligence.

[SEGMENT 00] Statut

Ce papier ne démontre rien. Il documente.

La distinction n'est pas rhétorique. Une démonstration établit qu'une proposition est vraie ; une documentation établit qu'un objet existe et décrit sa structure. NOEMA ne prétend pas que la méthode qu'il décrit produit de la vérité, de l'excellence, ou la forme que prendra l'intelligence à venir. Ces trois prétentions sont, dans l'ordre, invérifiable, circulaire, et prophétique. La première supposerait un accès à une correction formelle que l'opérateur n'a pas. La seconde s'auto-valide par les artefacts qu'elle invoque comme preuve. La troisième prédit un monde qu'aucune observation présente ne contraint. Aucune n'est tenue ici.

Ce qui est tenu est plus étroit, et plus dur. D'abord un fait : il existe un mode de production où un opérateur non-exécutant formel produit des artefacts formellement falsifiables, et ce mode a une structure analysable. Ensuite une thèse, et c'est la seule que le papier avance frontalement : là où l'exécution est devenue délégable, un critère concurrent de production intellectuelle devient observable, qui ne se mesure plus à l'exécution mais à l'orchestration. Le papier ne dit pas que la méthode est bonne ; il dit que le critère selon lequel on la jugerait faible, l'exécution formelle individuelle, est en train de cesser d'être le bon. Cette thèse n'est pas soustraite à la réfutation :

elle est exposée comme tout le reste, et elle tombe le jour où l'exécution redevient le centre de gravité de la compétence. L'objet du papier est cette structure et ce déplacement, non la valeur de la méthode.

Sur la fiabilité, la position est arrêtée, et elle se pose par axe, non en bloc. Sur l'axe systémique (équipes adverses dédiées, incitations adversariales institutionnalisées, diversité organisationnelle, déploiement étagé), l'enveloppe de vérification d'une institution qui fait tourner la même récursion reste supérieure à ce que l'opérateur (lui-même, une topologie de modèles de familles distinctes, puis l'exposition publique du produit) peut assembler, et le papier ne revendiquera à aucun moment le contraire. Sur l'axe de la vérification formelle locale, en revanche, la relation n'est pas tranchée : une cascade de familles hétérogènes peut, sur des sous-domaines précis, atteindre ou dépasser une relecture humaine isolée ; c'est l'objet du test A.1, non un acquis, et le pilote de l'annexe B en donne un signal daté, sans bras humain de comparaison. Le papier refuse donc le jugement monolithique dans les deux sens : ni « l'institution vérifie mieux partout », ni « la cascade vérifie mieux partout ». Il revendique seulement que le dispositif suffit à produire un objet *falsifiable* : un artefact exposé à sa réfutation, et non protégé d'elle. C'est moins qu'une garantie. C'est plus que la quasi-totalité du travail qui ne s'expose pas du tout.

Le nom dit l'objet. En phénoménologie, le *noéma* est l'objet tel qu'il est visé, le contenu d'une intention, distinct de l'acte qui le vise et de la chose qui le réalise. C'est exactement ce que l'opérateur, et lui seul, apporte à la chaîne : non l'exécution, non la preuve, mais l'objet visé avant qu'il existe. Tout le reste est délégué. Ce qui ne peut pas l'être, ce qui reste irréductiblement humain dans la boucle, c'est le noéma. Le papier porte le nom de la seule chose qu'il attribue à l'opérateur.

Les limites de ce papier sont cartographiées au segment [07], et chacune de ses affirmations est, dans le corps du texte, exposée à la réfutation qui la viserait. Là où une affirmation ne peut pas être réfutée, elle est signalée comme telle et retirée du compte des résultats. Ce qui survit n'est pas vrai. C'est non encore réfuté.

[SEGMENT 01] Déplacement

Dans le régime classique de la production savante, la compétence se confondait avec l'exécution : savoir dériver, calculer, coder, démontrer, vérifier soi-même. L'opérateur incapable d'exécuter était structurellement disqualifié, et cette disqualification était rationnelle tant que l'exécution restait rare, coûteuse et principalement humaine. Ce régime se referme à mesure que l'exécution se délègue. Quand l'exécution formelle devient délégable à des modèles qui dépassent l'opérateur sur des sous-domaines précis, le centre de gravité de la compétence se déplace : la question décisive n'est plus qui sait exécuter, mais qui sait viser, décomposer, router, contrôler, recomposer, détecter les dérives et exposer à la réfutation ce qu'il ne peut pas exécuter lui-même. C'est le passage d'une intelligence d'exécution à une intelligence d'orchestration.

Une hiérarchie doit être posée d'emblée, car elle structure tout le papier. Ces verbes décrivent le rôle de l'opérateur dans la fenêtre présente, non son socle : la plupart d'entre eux (décomposer, router, contrôler, recomposer) sont eux-mêmes partiellement déléguables, et le segment [03] documente qu'ils sont effectivement délégués. Seules deux fonctions résistent structurellement à la délégation, et le segment [04] établit pourquoi : tenir l'intention, détecter l'écart à l'intention. Le rôle est contingent et daté ; le socle ne l'est pas. Confondre les deux exposerait le papier à une objection facile : que son « intelligence d'orchestration » se réduise, à terme, à deux fonctions. C'est exactement ce que le papier soutient, et il le soutient d'avance.

L'erreur de l'ancien régime est de confondre l'incapacité d'exécuter avec l'incapacité de produire. Tant que l'exécution était le goulot, la confusion était sans conséquence : les deux incapacités coïncidaient. Elles se séparent dès que l'exécution se délègue. NOEMA documente ce point de séparation. Il ne prétend pas que l'orchestration remplace toute expertise ; il soutient que l'expertise d'exécution cesse d'épuiser la définition de la compétence productive, et qu'une autre compétence, post-exécutive, topologique, intentionnelle, occupe désormais le lieu où le coût ne s'effondre pas encore ([06]).

Déléguer l'exécution formelle à une machine n'est pas nouveau. C'est la trajectoire dominante de la cognition outillée depuis un demi-siècle : la calculatrice, le compilateur, le solveur, le supercalculateur. À chaque étape, l'exécution descend dans l'outil et la valeur cognitive remonte vers le cadrage et le jugement. Lue comme la suite de cette série, l'orchestration d'inférence ne serait qu'un cran de plus. Cette lecture est fausse, et la corriger est tout l'objet du déplacement.

L'outil formel classique échoue de façon bornée et détectable. Une calculatrice qui se trompe ne se trompe pas plausiblement : sa défaillance est hors-distribution, visible, ou inexistante. Le modèle d'inférence échoue autrement. Il échoue *silencieusement* : il produit une sortie cohérente, syntaxiquement valide, structurellement plausible, et fausse, sans émettre aucun signal distinguant ce cas du cas correct. Le phénomène n'est pas hypothétique : l'annexe B en consigne une instance datée, une somme fausse validée « CLEAN » à huit passes consécutives par deux familles distinctes. C'est une classe de défaillance que l'outillage formel antérieur ne connaissait pas. Si l'exécutant délégué échouait comme une calculatrice, l'orchestration serait triviale et n'exigerait aucune méthode. La méthode existe précisément parce que l'exécutant dépasse l'opérateur sur l'axe formel *et* le trompe sur l'axe de la fiabilité, dans le même geste.

Le déplacement n'est donc pas « on délègue le formel comme toujours ». Il est : pour la première fois, on délègue à un exécutant supérieur et à défaillance silencieuse, et l'orchestration est la réponse structurelle à cette configuration sans précédent.

Cette configuration n'est pas spéculative. C'est ainsi que sont déjà produits les artefacts d'intelligence artificielle les plus avancés : des modèles servent à entraîner, corriger et durcir des modèles plus puissants,¹ sous une couche de capture de défaillance que les institutions assurent à l'échelle industrielle.² La récursion fonctionne ; elle est observée, pas anticipée. Mais dans sa forme institutionnelle, la contribution proprement humaine y est inanalysable : elle est répartie sur des milliers d'acteurs, des processus, des outils, et noyée dans la complexité de l'organisation. On ne peut pas y lire ce que l'humain apporte, parce qu'on ne peut pas l'isoler.

C'est ici que l'instance solo cesse d'être une faiblesse. Un opérateur unique exécutant la même récursion, sans enveloppe institutionnelle, est le cas expérimental propre du pattern : la variable « orchestration humaine » y est isolée du reste. Ce que cet opérateur fait, et ce qu'il ne peut structurellement pas garantir, devient lisible précisément parce qu'il n'y a personne d'autre dans la boucle. Le $n = 1$ n'est pas l'aveu d'un manque de généralité ; c'est le dispositif qui rend la fonction humaine observable. Le *pattern*, lui, n'est pas singulier : la production par délégation d'inférence est déjà le mode observé des artefacts les plus avancés. Seule l'est la variante solo, et le $n = 1$ y vaut comme preuve d'existence : il établit qu'un opérateur unique peut la réaliser, non que beaucoup le pourraient.

¹L'apprentissage par renforcement sur retour de modèle (RLAIF) et les données synthétiques sont devenus des méthodes par défaut du post-entraînement ; voir Bai *et al.* (2022) et Lee *et al.* (2023) en références.

²Cette « enveloppe » a un nom dans la littérature : c'est le problème de la *supervision à l'échelle* (scalable oversight ; Amodei *et al.* 2016) : superviser un exécutant qui dépasse le superviseur sur l'axe de la tâche. La délégation de la vérification à d'autres modèles (debate, Irving *et al.* 2018 ; amplification itérée, Christiano *et al.* 2018 ; Constitutional AI et RLAIF, Bai *et al.* 2022) en est la réponse institutionnelle. NOEMA en isole la variante solo ; il ne la réinvente pas.

L'objet d'analyse, dès lors, n'est ni le produit, ni les modèles, ni la topologie qui les relie. C'est le **résidu incompressible** : ce que la chaîne ne peut pas absorber sans se dégrader. Tout ce qui peut être délégué l'est, et l'est mieux qu'un humain ne le ferait. Ce qui reste, après que tout le déléguable a été délégué, n'est pas ce que l'opérateur fait le mieux, c'est ce que personne d'autre dans la chaîne ne peut faire à sa place. Le papier ne s'intéresse qu'à ce reste.

[SEGMENT 02] Topologie de délégation

La chaîne n'est pas une délégation ; c'est une topologie. Chaque nœud est un modèle, doté d'un profil de compétence (les domaines où il dépasse l'opérateur) et d'un profil de zone aveugle (les erreurs qu'il ne perçoit pas). Déléguer ne consiste pas à confier une tâche à « l'IA » ; c'est router chaque sous-problème vers le nœud dont la compétence le couvre et dont la zone aveugle, sur ce sous-problème précis, est minimale. La fonction de l'opérateur en amont de la chaîne est cette dissolution : découper l'objet visé en sous-problèmes assez précis pour qu'un nœud spécialisé les absorbe sans ambiguïté, puis recomposer le produit.

Ce formalisme ne mesure pas une fiabilité effective ; il décrit la structure minimale qui rend la dépendance aux zones aveugles lisible. Formellement, soit un ensemble de nœuds $M = \{m_1, \dots, m_p\}$ et un objet décomposé en sous-problèmes $\{s_1, \dots, s_q\}$. On note Ω l'espace des défaillances qu'un artefact peut contenir, muni d'une mesure de probabilité μ (les masses ci-dessous sont donc normalisées, et leurs produits ont un sens), et l'on associe à chaque vérificateur m_i une *zone aveugle* $B_i \subset \Omega$: l'ensemble des erreurs que m_i ne détecte pas.³ La délégation δ envoie s_j vers le ou les nœuds couvrant s_j et y minimisant la zone aveugle. Mais le point structurel n'est pas la délégation ; c'est la vérification.

Une erreur e présente dans une sortie survit à une cascade de vérificateurs $\{v_1, \dots, v_r\}$ si et seulement si aucun ne la détecte, c'est-à-dire

$$e \in \bigcap_{i=1}^r B_i.$$

L'indépendance des zones aveugles est le cas-limite favorable : si elle tenait, la mesure de l'intersection s'effondrerait avec le nombre de vérificateurs, $\mu(\bigcap_i B_i) = \prod_i \mu(B_i) \rightarrow 0$, et une cascade assez longue garantirait la correction. Elle ne tient pas ; et c'est la corrélation des zones aveugles, non leur nombre, qui gouverne ce qui survit.

Des modèles entraînés sur des corpus recouvrants partagent des erreurs de raisonnement :

³Idéalisation assumée : la détection réelle est stochastique : un vérificateur manque une erreur avec une probabilité dépendant du contexte, non par appartenance à un ensemble fixe. Le modèle ensembliste est le cas dégénéré qui suffit à l'argument (séparer le nombre de la diversité) ; une version probabiliste en compliquerait les bornes sans en changer le sens.

leurs zones aveugles se recourent.⁴ Il subsiste un plancher

$$F = \mu\left(\bigcap_{i \in \mathcal{S}} B_i\right) \geq 0, \quad \Pr(e \text{ survit}) \geq F,$$

où $\mathcal{S}$ est l'ensemble des sphères employées. Ce plancher n'est pas réductible par l'allongement de la cascade.

Ce qu'est une sphère. Une *sphère* n'est pas un modèle ; c'est la classe des vérificateurs qui partagent l'essentiel de leur zone aveugle : même famille de pré-entraînement, même matière de fine-tuning, même niveau d'abstraction. Le critère est opérationnel et doit être *antérieur* à l'épreuve : deux vérificateurs relèvent de la même sphère si l'on peut prédire, avant de les confronter à l'artefact, qu'ils manqueront les mêmes erreurs. Cette antériorité n'est pas un raffinement ; elle est ce qui rend l'énoncé falsifiable. Sans elle, on pourrait toujours, après coup, baptiser « nouvelle sphère » tout vérificateur qui se trouve voir une erreur, et la thèse « une sphère décorrélée fait décroître F » deviendrait invérifiable par construction. La partition en sphères est donc déclarée avant le contrôle, jamais ajustée après lui.

Le plancher comme fonction de la corrélation. Un modèle minimal, posé pour rendre la dépendance lisible et non pour la mesurer, suffit à séparer le nombre de la diversité. À chaque paire de sphères, associons le recouvrement de leurs zones aveugles

$$\rho_{ij} = \frac{\mu(B_i \cap B_j)}{\min(\mu(B_i), \mu(B_j))} \in [0, 1],$$


avec $\rho_{ij} = 1$ pour deux vérificateurs d'une même sphère (zones emboîtées, $B_j \approx B_i$) et $\rho_{ij} \rightarrow 0$ pour des sphères sans erreur commune. Le plancher d'une cascade est alors encadré par ses deux pôles :

$$\underbrace{\prod_i \mu(B_i)}_{\rho=0 \text{ (indépendance)}} \leq F = \mu\left(\bigcap_{i \in \mathcal{S}} B_i\right) \leq \underbrace{\min_i \mu(B_i)}_{\rho=1 \text{ (même sphère)}}.$$

La borne haute porte tout l'argument : ajouter un vérificateur dont la corrélation ρ aux sphères déjà présentes est proche de 1 laisse F à son maximum (un coût sans gain). Seul un vérificateur à ρ faible tire F vers la borne basse. La variation de F est donc essentiellement nulle en fonction du *nombre* de passes dès que ρ est élevé (rigoureusement nulle au seul cas-limite des zones emboîtées), et négative en fonction de la *décorrélation*. C'est l'énoncé exact, et déjà classique, de la condition sous laquelle un collège de juges faillibles devient fiable : compétence *et* indépendance, jamais l'effectif seul.⁵ Une distinction est nécessaire pour que l'énoncé soit exact,

⁴Le fait n'est pas propre aux modèles d'inférence, ni conjecturé par ce papier. Knight et Leveson (1986) ont montré expérimentalement que des programmes développés indépendamment pour une même spécification partagent des fautes corrélées : l'hypothèse d'indépendance du *N-version programming* échoue empiriquement. Eckhardt et Lee (1985) en avaient donné le modèle théorique : il suffit que la difficulté varie selon les entrées pour que des versions développées indépendamment échouent ensemble ; le recouvrement ρ_{ij} utilisé ici est la version ensembliste de cette intensité de défaillance coïncidente. La corrélation des défaillances entre exécutants construits séparément est un résultat observé d'un régime technique antérieur ; les modèles d'inférence, entraînés sur des corpus largement communs, n'ont aucune raison d'y échapper et toutes d'y être plus exposés. La littérature sur l'évaluation par modèle va dans le même sens : les juges-modèles présentent des biais systématiques et partagés (auto-préférence, biais de position ; Zheng *et al.* 2023), c'est-à-dire des zones aveugles corrélées au sens de ce segment ; et le gain de la confrontation entre instances ou familles distinctes sur la factualité (Du *et al.* 2023) est la lecture positive du même fait.

⁵C'est, pour des vérificateurs au lieu de votants, la structure du théorème du jury de Condorcet (1785) : la fiabilité collective ne croît avec l'effectif que si les jugements sont à la fois compétents et indépendants ; sous erreurs corrélées elle plafonne. Le même fait gouverne la diversité des ensembles en apprentissage statistique, où un ensemble ne gagne sur ses membres qu'à proportion de la décorrélation de leurs erreurs.



Structure de la chaîne : l'intention descend en tâches, la vérification se fait ailleurs, le produit remonte sous contrôle de fidélité. Le plancher F est interne au pipeline ; seules des sphères qui en sont absentes (exposition publique, [05]) réduisent le résidu $\bigcap_i B_i$. Schéma structurel, sans prétention métrique.

et elle préempte l'objection la plus prévisible. Les défaillances de détection ont deux composantes : un *bruit de passe* (le vérificateur manque une erreur à une passe et la voit à la suivante) et un *angle mort stable* (il la manque à toute passe). La répétition au sein d'une même sphère réduit la première composante, c'est le gain documenté de l'auto-cohérence par échantillonnage répété (Wang *et al.* 2022), mais ne touche jamais la seconde : elle ramène la détection vers le plancher de la sphère, elle n'abaisse pas ce plancher. L'énoncé exact est donc : le nombre épuise le bruit, seule la diversité entame le plancher. Cette prédiction (la diversité fait décroître F , le nombre non) a fait l'objet d'un premier pilote daté, rapporté en annexe B ; il l'expose à réfutation et ne la réfute pas, ses donnéesinstancient les deux composantes séparément, et elles montrent qu'une partition par famille peut surestimer la diversité réelle : deux familles distinctes y partagent un angle mort, et l'estimateur de recouvrement correspondant y atteint $\hat{\rho} = 1$ sur les angles morts stables : le recouvrement maximal, mesuré entre deux sphères déclarées distinctes avant l'épreuve.

La conséquence opérationnelle inverse l'intuition. La méthode ne consiste pas à revérifier davantage ; elle consiste à revérifier *ailleurs*, à ne jamais rester dans la même sphère : toute passe supplémentaire à ρ élevé est dépensée pour rien. Le re-contrôle par des modèles d'autres familles, à d'autres niveaux, fine-tunés sur d'autres matières, vise précisément à faire décroître $\bigcap_i B_i$ jusqu'à un plancher comparable à celui d'un relecteur humain spécialisé isolé, dont la zone aveugle B_h n'est, elle non plus, pas vide.

La cible de conception est cette parité : $F_{\text{int}} \leq \mu(B_h)$, le plancher interne ramené sous celui d'un expert seul. C'est une cible, non un résultat mesuré : l'opérateur ne peut pas la vérifier, puisqu'il ne sait pas exécuter la matière ; elle relève d'un protocole de mesure (injection d'erreurs connues, comparaison à une relecture experte sur artefacts à défauts contrôlés) explicitement renvoyé aux travaux futurs. Et sous toute parité atteinte subsiste l'erreur logée dans $\bigcap_{i \in \mathcal{S}} B_i$: la classe qu'aucune sphère employée ne voit. Aucune cascade interne ne l'atteint, par définition. Seule une sphère absente du pipeline le peut. C'est l'objet du segment [05].

[SEGMENT 03] **Instanciation**

La topologie de [02] est une structure abstraite : des nœuds, des zones aveugles, une fonction de routage. Ce segment en donne l'instance, la forme matérielle qu'a prise la chaîne sur l'artefact qui motive ce papier (EIDOLON, cf. infra). Tout y est documenté comme instance, non comme mesure : ni les capacités des modèles cités, ni l'efficacité de l'agencement ne sont vérifiées ici, et aucune affirmation du papier n'en dépend. Le segment décrit la chaîne non comme un mode d'emploi (tel modèle, tel prompt) mais comme un protocole d'instanciation : comment une intention non sérialisée devient un ensemble de tâches déléguables, exécutées par des nœuds spécialisés, contrôlées par des sphères décorréées, puis recomposées sous une autorité que les modèles ne possèdent pas entièrement.


Le substrat : une base de contexte centralisée. Avant tout routage, il y a un lieu où l'intention prend corps. L'opérateur maintient une base de connaissance unique et centralisée (un graphe de notes liées, de type *Obsidian*) où il dépose, structure et relie le contexte d'un objet avant de déléguer quoi que ce soit. Cette base est l'organe d'*accès explicite* de l'opérateur : la part de son intention qu'il parvient à sérialiser y est écrite, liée, rendue interrogeable : de la cognition étendue au sens de Clark et Chalmers (1998), à ceci près que son rôle ici n'est pas d'augmenter l'esprit mais d'en tracer la frontière. Elle n'est pas le résidu non sérialisable de [04] ; elle en est exactement le complément : tout ce qui peut être externalisé l'est ici, ce qui isole *par soustraction* ce qui ne le peut pas. La base n'est pas un outil de productivité ; c'est la frontière matérielle entre le déléguable et l'indéléguable.

Les modèles qui écrivent dans la base. Sur ce substrat, l'opérateur connecte une pluralité de modèles, locaux et distants, et leur fait *déposer leur savoir* dans la base : non pas seulement exécuter une tâche et rendre une sortie, mais écrire ce qu'ils savent d'un sous-problème, en addition du contexte déjà présent. Chaque nœud enrichit le graphe d'une strate propre ; la base agrège des couches d'origines hétérogènes. C'est la contrepartie concrète de la diversité des sphères de [02] : faire écrire des familles distinctes dans un même lieu, c'est juxtaposer sur un même contenu des zones aveugles peu corrélées : la condition, et la seule, sous laquelle $\bigcap_i B_i$ décroît.

La gouvernance : la puissance contextuelle en tête de chaîne. Les nœuds ne sont pas égaux et la chaîne n'est pas plate. L'opérateur la hiérarchise par puissance contextuelle : les modèles dont la tenue du contexte long et la fiabilité de jugement sont les plus hautes occupent le sommet de la chaîne de gouvernance : ils arbitrent, médient les désaccords inter-agents, contrôlent les couches inférieures ; les modèles plus étroits exécutent en aval, sous ce contrôle. Le routage de [02] n'est donc pas seulement horizontal (quel nœud pour quel sous-problème) mais vertical : quel nœud contrôle quel nœud. Garder les modèles les plus puissants en tête n'est pas une déférence à la marque ; c'est placer la plus large zone de compétence là où elle vérifie le plus de couches.

L'architecture est refaite par sujet. Il n'y a pas une topologie ; il y en a une par objet. Chaque sujet impose sa propre décomposition, donc son propre agencement de nœuds, de rôles et de contrôles. L'opérateur construit l'architecture en fonction de la matière : ce qui était garde-fou de gouvernance sur un objet devient exécutant sur un autre, ce qui était sous-agent d'arrière-plan remonte en vérification ailleurs. La fonction δ de [02] n'est pas un paramètre fixe ; c'est ce que l'opérateur reconstruit à chaque objet, et cette reconstruction est déjà une part de la spécification d'intention de [04].

Le mouvement. Décrits comme composants, ces éléments restent immobiles ; le protocole est dans leur enchaînement. Le premier geste n'est pas de produire un objet mais de le rendre



Base de contexte centralisée (type Obsidian). L'opérateur contextualise une partie du graphe ; chaque modèle connecté lit et modifie ensuite le contexte et les tâches du projet selon son rôle, sous contraintes de gouvernance et de traçabilité. Le nœud central condense l'objet visé ; les couleurs distinguent les strates d'origine hétérogène déposées par les différents nœuds. Graphe réel, à valeur illustrative et non métrique.

délégable. L'opérateur prend le problème dans son état brut (intuition, contrainte, tension théorique, hypothèse encore mal formée) et le convertit d'abord en base : il y écrit ce qui peut l'être (objectifs, définitions provisoires, critères de réussite et d'échec, zones obscures, risques de dérive), c'est-à-dire la part sérialisable de l'intention. De cette base naît une décomposition provisoire en sous-problèmes, que la chaîne elle-même corrigera. Les modèles de gouvernance convertissent l'intention sérialisée en plan opératoire (quelles tâches isoler, quels nœuds mobiliser, quoi faire vérifier ailleurs) ; les nœuds spécialisés exécutent ; d'autres sphères relisent, contestent, recomposent. Aucune de ces fonctions ne détient l'autorité sur l'objet : elle reste à l'opérateur, non comme meilleur exécutant mais comme seul porteur du noéma. Sa souveraineté ne consiste pas à produire chaque état, mais à pouvoir interrompre, réorienter ou invalider la chaîne dès qu'elle devient cohérente contre l'intention. Ce que [02] énonce comme routage et [04] comme résidu, le protocole le donne à voir comme un mouvement : l'intention descend en tâches, la vérification se fait ailleurs, le produit remonte sous contrôle de fidélité.

Topologie temporelle. À cela s'ajoute une exigence que la topologie abstraite de [02] ne montrait pas : la trace. Chaque intervention significative laisse une *trace de transition*, qui documente le passage d'un état du projet au suivant. Son format minimal est fixe : identifiant de l'intervention, date, nœud ou sphère intervenante, état du contexte reçu, tâche traitée, intention locale, modification apportée, justification, incertitudes restantes, dépendances créées, points à

vérifier, et statut de validation ou de contestation. De façon condensée,

$$\text{trace} = \{ \text{acteur, sphère, contexte, intention locale, modification,} \\ \text{justification, incertitude, dépendances, vérifications} \}.$$

Ce format n'est pas une métaphore : c'est ce qui rend la dérivation effectivement rejouable plutôt que seulement narrée. La chaîne cesse alors d'être seulement un réseau de nœuds : elle devient une succession d'états du projet. Un nœud ne reçoit pas qu'une sortie ; il reçoit un état historique, qu'il peut prolonger, corriger, contester ou invalider. La conséquence est structurelle : l'objet inspectable n'est plus seulement l'artefact final, mais la transition qui l'a produit. Une erreur peut être cherchée dans la décision, l'interprétation ou la bifurcation qui l'a introduite, non plus seulement dans le résultat. Le principe de [02] (faire voir l'erreur par une sphère décorrélée) s'applique dès lors aux transitions autant qu'aux sorties. Ce qui devient inspectable n'est plus seulement le produit, mais sa dérivation ; cette inspection reste toutefois interne au pipeline. L'exposition publique de [05], elle, porte au minimum sur l'artefact final, et sur les traces seulement si celles-ci sont publiées.

La configuration d'EIDOLON. L'objet qui a motivé ce papier est EIDOLON, moteur d'inférence probabiliste sous pression sur graphe de croyances pour l'analyse OSINT : le système dont le segment [05] fait la cible de réfutation publique, déposé en accès ouvert.⁶

EIDOLON n'est pas un prétexte ; c'est un artefact à contenu formel déterminé, et c'est ce contenu qui le rend réfutable. Le système modélise une entité cible comme un graphe de croyances typé sous contrainte structurelle : des nœuds porteurs de priors bayésiens et de modèles de résistance à la déformation, des arêtes typées à conductivité propre, un moteur de propagation de croyances (*Loopy Belief Propagation* à portes Noisy-OR/AND), un modèle de pression à stimuli dirigés dont le signal analytique est la résistance observée plutôt que la réponse, un solveur de sélection de stimulus corrigeant un biais de saturation identifié, et une couche topologique (homologie persistante) isolant cycles de renforcement et nœuds-ponts. Chacun de ces composants expose des affirmations falsifiables d'un type précis : correction mathématique des dérivations, validité des algorithmes implémentés, cohérence du cadre probabiliste. Sa réfutation aurait une forme concrète : une dérivation fausse, un estimateur biaisé autrement que documenté, une propriété topologique mal établie. C'est cette précision qui sépare un artefact *exposé* d'un texte simplement publié, et c'est elle que [05] présuppose.

La configuration qui l'a produit était la suivante. Le tableau documente une répartition de rôles, non une propriété des modèles ; les noms désignent des familles, sans engagement sur une version. Ce n'est pas un défaut de l'instance : ce qui rend l'artefact publiquement falsifiable n'est pas l'identité versionnée des nœuds qui l'ont produit, mais l'exposition du produit lui-même ([05]). La traçabilité interne, elle, ne vaut pas comme preuve externe ; elle rend seulement la dérivation inspectable, contestable et partiellement rejouable à l'intérieur du pipeline.

⁶DOI: <https://doi.org/10.5281/zenodo.20365831>. Le moteur lui-même est déposé en source ouverte (<https://github.com/zeroday450/EIDOLON>) : l'exposition de [05] porte sur le code autant que sur le texte.

Nœud	Rôle déclaré
Claude Opus	Co-design d'architecture : choix du moteur, décisions architecturales au niveau du contexte.
Claude Sonnet	Vérification formelle du moteur : implémentation des modules analytiques, revue itérative à six dimensions : correction mathématique, intégrité du code, architecture, documentation, cohérence interne, validité scientifique.
Qwen	Configuration multi-agents : coordination d'un pipeline de quinze agents.
GPT	Garde-fou de gouvernance : auto-gouvernance des choix architecturaux, médiation des discussions inter-agents.
Kimi	Sous-agent d'arrière-plan : exécution asynchrone de tâches.
Perplexity	Organisation des sous-agents : structuration de la recherche et orchestration des sous-tâches.

L'opérateur a maintenu la supervision et l'autorité finale : toutes les formulations théoriques, décisions de calibration et jugements de publication lui reviennent.

Une réserve, par cohérence avec [02] : Claude Opus et Claude Sonnet relèvent de la *même* sphère (même famille de pré-entraînement). La revue à six dimensions confiée à Sonnet est donc une vérification largement *intra-sphère* : par l'argument de [02], elle durcit la sortie mais ne fait pas décroître F à elle seule. La décorrélation effective de cette instance vient des familles distinctes (Qwen, GPT, Kimi, Perplexity), et surtout de l'exposition externe de [05]. Le tableau documente une instance réelle, y compris là où elle est sous-optimale au regard du critère du papier : c'est une instance, non une démonstration de la méthode.

Une seconde instance datée, sur une matière différente (logiciel de supervision industrielle sous contraintes physiques) et une topologie différente (deux familles en alternance, mémoire canonique partagée, journaux append-only par agent), est documentée en annexe C ; elle donne au format de trace ci-dessus son instance de terrain, et au test A.5 son premier pilote observationnel.

[SEGMENT 04] Les deux fonctions non-déléguables

La cascade de [02] délègue et vérifie tout ce qui est formel. Après elle, que reste-t-il à l'humain ? Pas les sept verbes de [01] : quatre d'entre eux (décomposer, router, contrôler, recomposer) sont au moins partiellement déléguables, et [03] a documenté leur délégation effective ; un cinquième, *exposer*, n'est pas une fonction cognitive mais un acte public, traité à part en [05]. Ces cinq appartiennent au rôle daté de l'opérateur, que la trajectoire des modèles érode. Restent deux fonctions, d'une autre nature : *viser* (tenir l'intention) et *détecter* l'écart à l'intention. Non parce que l'humain les exécuterait mieux qu'un modèle (il ne les exécute pas mieux) mais parce que les déléguer est structurellement impossible : chacune, pour être déléguée, se présupposerait elle-même.

Première fonction : l'intention. Déléguer un sous-problème suppose une spécification : la cible vers laquelle router. La fonction δ prend en entrée un objet déjà visé. Déléguer la définition de cet objet exigerait une spécification de second ordre (quoi demander au modèle chargé de spécifier) qui exigerait à son tour une spécification de troisième ordre, sans terme. La spécification de l'intention est le point fixe qui arrête la régression. Un modèle peut produire *une* intention ; mais juger si c'est l'intention voulue requiert une intention antérieure pour servir d'étalon. La régression ne s'arrête qu'à un fond non délégué. Ce fond est l'entrée de la chaîne,

et il est humain par nécessité logique, non par privilège.

Cette intention n'est jamais entièrement sérialisable. Si l'opérateur pouvait écrire la spécification complète dans une consigne, le reste serait délégable et l'opérateur, redondant sur cet axe aussi. La part irréductible est exactement le reste non sérialisable, ce que l'opérateur vise sans pouvoir l'externaliser en entier. C'est ce que la base de [03] rend visible en creux : elle reçoit tout ce qui se sérialise, et ce qui n'y entre jamais est, par construction, le résidu. L'opérateur se décrit comme un système à encodage massivement implicite et à accès explicite étroit : il maintient des représentations qu'il ne transfère pas intégralement vers une forme déclarable. Cette description explique *pourquoi*, pour cet opérateur, le reste non sérialisable est grand ; elle ne démontre pas qu'un tel reste soit non sérialisable en principe. L'argument structurel (une intention entièrement sérialisable serait délégable) tient indépendamment de la description cognitive, qui n'est ici qu'une motivation, jamais une prémisse.

Deux affirmations doivent être tenues séparées. La première (*il existe* un germe d'intention non délégué) est établie par la régression, et elle est intemporelle : tant qu'il y a délégation, il y a une spécification première qui n'en est pas une. La seconde (ce germe est *substantiel*, assez grand pour porter une valeur) n'est pas établie par la régression ; elle dépend de la grandeur du reste non sérialisable, qui est une quantité empirique et datée. La régression prouve le point trivial (une entrée existe) ; toute la valeur du papier repose sur le point non trivial (cette entrée est grande), qui demeure une hypothèse, cartographiée comme telle en [07]. Confondre les deux ferait passer une nécessité logique pour une nécessité de fait. NOEMA maintient l'écart : il prouve qu'un résidu existe, il *suppose* qu'il est grand.

Seconde fonction : la détection, et son niveau exact. La précision est nécessaire, car [02] a déjà délégué la vérification de la correction formelle à la cascade. La seconde fonction n'est donc pas la détection des défaillances formelles silencieuses : l'opérateur ne sait pas les voir, il ne sait pas exécuter la matière. Elle est la détection de l'écart entre l'artefact réalisé et la part non sérialisée de l'intention. Un artefact peut être intérieurement correct (validé par la cascade), cohérent, plausible, et n'être pas ce qui était cherché. La cascade vérifie la correction relative à la consigne qu'elle a reçue ; elle ne peut pas vérifier la fidélité à la part de l'intention qui n'est entrée dans aucune consigne, puisqu'elle ne l'a jamais eue. Seul le porteur du noéma détecte cette dérive. La fonction doit toutefois être découpée à son grain exact, car l'objection est prévisible : le *repérage* d'écarts candidats est délégable : un nœud qui relit la base et les traces peut signaler des dérives possibles, et l'annexe C documente des dérives détectées par la sphère croisée avant l'opérateur. Ce qui ne l'est pas, c'est l'*adjudication* : juger qu'un candidat est bien un écart à l'intention voulue requiert l'étalon non sérialisé, par la régression ci-dessus. La non-délétabilité porte sur le jugement, jamais sur l'alerte.

Les deux fonctions sont duales : la première tient l'intention non sérialisable, la seconde détecte l'écart à cette intention. Toutes deux reposent sur le même reste. Il n'y a pas deux résidus ; il y en a un, à deux faces.

Ce que cela délimite, c'est précisément ce que l'opérateur *ne peut pas* attraper. Une défaillance qui serait à la fois formellement correcte, cohérente, *et* fidèle à l'intention complète, mais fausse sur le monde, franchit tout. Si l'intention elle-même est erronée, aucune des deux fonctions ne le détecte : le résidu garantit la fidélité à l'intention, jamais la justesse de l'intention. L'opérateur est le garant de la fidélité, rien de plus. Et même cette garantie est exposée : si le reste non sérialisable est illusoire (si l'opérateur croit seulement tenir plus qu'il n'a écrit), la seconde fonction détecte du bruit. Le reste non sérialisable est posé comme hypothèse de travail, non comme fait établi ; le protocole qui la réfuterait est donné en annexe A (test A.4).

L'inversion du chercheur. Le chercheur part d'un sol formel (axiomes, structures) et dérive

vers l'avant jusqu'à des hypothèses et des résultats ; la validité descend du sol. L'opérateur part de l'intention, la dissout en sous-problèmes déléguables, fait exécuter et révéifier ailleurs la dérivation formelle, puis recompose. Il arrive au formel *malgré lui* : les mathématiques ne sont pas l'origine mais le terme. Ce n'est pas une méthode inférieure ; c'est l'autre sens de la même dépendance. Le chercheur garantit la correction par construction depuis le sol, mais reste borné par ce qu'il peut lui-même dériver. L'opérateur n'est pas borné par sa propre capacité formelle, mais ne garantit rien par construction : seulement la fidélité à l'intention, la correction étant close en aval. L'inversion achète la portée au prix de la garantie interne. C'est un échange, non un gain net.

Le chercheur sait pourquoi son résultat est vrai. L'opérateur sait seulement ce qu'il cherchait. Tout le reste est délégué, vérifié ailleurs, et exposé.

[SEGMENT 05] Exposition externe

Le segment [02] a laissé un résidu d'erreur : $\bigcap_{i \in \mathcal{S}} B_i$, la classe d'erreurs qu'aucune sphère employée ne voit. Aucune cascade interne ne l'atteint, par construction. Ce segment traite la seule opération qui le peut.

Publier en open-source, c'est ajouter au dispositif des sphères qui en étaient absentes. Un relecteur humain expert porte une zone aveugle B_h dont la corrélation aux sphères-modèles est faible : entraînement différent, pratique vécue, histoire d'erreurs propre. L'exposition publique soumet l'artefact à $\{B_{h_1}, B_{h_2}, \dots\}$, et la région d'erreur survivante devient

$$\left(\bigcap_{i \in \mathcal{S}} B_i \right) \cap \left(\bigcap_k B_{h_k} \right) \subseteq \bigcap_{i \in \mathcal{S}} B_i.$$

L'inclusion est stricte dès qu'un seul relecteur voit une erreur que toutes les sphères internes manquaient. C'est le gain de l'open-source : non la diffusion, mais le recrutement de zones aveugles que le pipeline ne pouvait pas contenir.

Mais l'exposition n'est pas la vérification. Trois états doivent être distingués, et le pipeline n'en livre qu'un.

- **Vérifié** : un relecteur compétent a fait le travail et n'a pas trouvé d'erreur, relativement à sa sphère.
- **Réfuté** : un relecteur a trouvé une erreur.
- **Exposé non lu** : publié, disponible, mais aucun relecteur compétent ne s'y est encore engagé.

Le pipeline livre par défaut le troisième état. Le premier exige un événement hors du contrôle de l'opérateur : que quelqu'un de capable lise et audite. Open-sourcer crée la *possibilité* du premier ou du deuxième état ; cela ne produit pas le premier. Un artefact « exposé non lu » n'est pas validé : il est seulement falsifiable. Son statut épistémique est « non encore réfuté », strictement plus faible que « vérifié ».

C'est le cadre poppérien posé exactement : la prétention de l'artefact à la correction est la prétention d'être exposé à la réfutation et de ne pas avoir été réfuté. EIDOLON en open-source, tant qu'aucun mathématicien n'en a audité une démonstration, est non réfuté, non prouvé. Le jour où l'un d'eux réfute, l'architecture a fonctionné comme prévu : elle a fait remonter l'erreur résiduelle qu'aucune sphère interne n'avait vue. La réfutation est un succès du dispositif, non son échec : c'est la propriété qui le sépare d'une idéologie.

La récursion institutionnelle garantit la vérification par construction : évaluations, équipes adverses, déploiement étagé tournent que l'extérieur s'y intéresse ou non. Sa clôture est interne et assurée, au prix d'une infrastructure énorme. La récursion solo ne garantit pas la vérification : sa clôture est externe, suspendue à un lectorat qui peut ne jamais venir. Sur cet axe, celui de la clôture garantie, elle est strictement plus faible ; la comparaison vaut là, et [00] dit pourquoi elle ne s'étend pas en jugement global. Son avantage structurel est que les sphères absentes qu'elle recrute (des experts humains indépendants, dispersés) sont potentiellement plus diverses que la revue interne de n'importe quelle institution. *Potentiellement* : le conditionnel porte toute la vulnérabilité. Une diversité qui ne lit pas ne réduit aucune intersection.

Reste le résidu qui survit même à cela. Avec cascade interne *et* lectorat externe, l'intersection de toutes les sphères, modèles et humains réunis, n'est pas prouvée vide. Le zéro erreur n'existe pas. Une classe d'erreurs peut être partagée par toute sphère qui examinera jamais l'artefact : une méconnaissance profonde, un angle mort de tout le champ. Ce résidu ne tend vers le vide qu'à la limite d'une diversité de relecture infinie, jamais atteinte. L'affirmation terminale honnête est donc bornée : l'architecture fait décroître la mesure de l'erreur survivante vers zéro sans l'y amener ; elle convertit « non vérifié par personne » en « exposé à la plus large diversité de sphères disponible ». C'est le statut épistémique le plus fort que la méthode puisse conférer. Pas la vérité. L'exposition maximale à la réfutation.

Un artefact que personne ne lit n'est pas faux : il est seulement intact. La clôture n'est pas dans la publication ; elle est dans la lecture que la publication rend possible, et que rien ne garantit.

[SEGMENT 06] Asymétrie de coût

La production intellectuelle classique a une structure de coût stable : l'exécution domine. Dériver, calculer, coder, vérifier consomme l'essentiel du temps et de la compétence rare ; le cadrage n'en est qu'une fraction. C'est sur cette structure que reposent l'organisation du travail savant et la valeur de l'expert : il est rétribué pour exécuter ce que peu savent exécuter.

L'orchestration inverse cette structure. L'exécution déléguée tend vers un coût marginal : rapide, peu chère, disponible en parallèle. Ce qui ne descend pas, c'est le coût des deux fonctions non déléguables : spécifier l'intention, détecter l'écart à l'intention. À mesure que le coût d'exécution s'effondre, le coût total de production tend vers le seul coût du résidu :

$$C_{\text{tot}}(n) = \underbrace{c_{\text{exec}}(n)}_{\rightarrow 0 \text{ par unité}} + c_{\text{int}}(n) + c_{\text{det}}(n) \longrightarrow c_{\text{int}}(n) + c_{\text{det}}(n),$$

où n mesure la complexité de l'objet produit. La relation est structurelle, non calibrée : elle dit où va le coût, pas combien il vaut.

Le coût résiduel ne descend pas ; surtout, il ne reste pas constant. Il croît avec n : plus l'objet est complexe, plus il y a d'intention à spécifier et de dérive à détecter. (Que c_{int} et c_{det} croissent avec n est une hypothèse de structure, non une mesure : on suppose seulement qu'un objet plus complexe porte plus d'intention à tenir, sans en calibrer la pente.) Le débit du système n'est donc plus borné par l'exécution : il est borné par la bande passante de l'humain sur l'intention et la détection. Le goulot d'étranglement migre de l'exécution vers le résidu. Là où l'institution était limitée par la capacité d'exécution, qu'elle résout par le nombre, l'opérateur solo est limité par sa propre capacité d'intention, qu'il ne peut pas multiplier.

Deux asymétries complètent cette structure, et elles sont les seules grandeurs du papier à être directement mesurables. La première est temporelle : l'exécution déléguée se fait en

parallèle et en heures là où l'exécution humaine équivalente se compte en jours ou en semaines ; le rapport des durées, à objet constant, est observable, et les traces de transition de [03], qui sont datées, suffisent à l'instrumenter côté chaîne (l'annexe C en fournit l'existence de terrain : quatre jours de traces datées en continu sur un projet réel). Les premières mesures de terrain sur tâches assistées vont dans ce sens (Dell'Acqua *et al.* 2023). La seconde est une asymétrie de reproduction : un exécutant-modèle se réplique à coût marginal, quand un exécutant humain coûte des années de formation par unité ; la capacité d'exécution disponible croît donc selon une dynamique sans équivalent du côté de la formation humaine. Aucune des deux n'établit la supériorité de la méthode : la vitesse n'a de valeur que sous le contrôle de fidélité de [04], et la réplification multiplie des copies, non des sphères (répliquer un nœud ne réduit pas $\bigcap_i B_i$, cf. [02]). Mais toutes deux pèsent sur la fenêtre de [01] : elles élargissent l'écart entre coût d'exécution et coût d'intention, et déplacent d'autant le goulot vers le résidu.

La précision importe : ce qui ne se délègue pas, c'est la détection de l'écart à l'intention, non la relecture formelle, déjà déléguée à la cascade de [02]. Une objection doit être traitée ici plutôt que laissée au lecteur : des modèles plus capables dérivent moins souvent de l'intention sérialisée, et la fréquence des écarts à détecter décroît donc avec leurs capacités. C'est exact, et le papier le concède : c_{det} baisse en fréquence. Mais chaque détection restante demeure humaine, puisque seul le porteur du noéma peut constater l'écart à ce qui n'a jamais été écrit : le coût *par détection* est incompressible alors même que le nombre des détections diminue. L'asymétrie stricte porte donc sur c_{int} : le coût d'exécution décroît avec les capacités des modèles (il s'améliore sans l'opérateur), tandis que le coût d'intention ne décroît pas avec elles. Il ne décroîtrait que si les modèles devenaient capables d'inférer l'intention non sérialisée, ce qui, par [04], reviendrait à supprimer la fonction humaine elle-même. L'asymétrie n'est donc pas un état ; c'est une tendance : l'écart entre coût d'exécution et coût d'intention s'élargit à mesure que les modèles progressent. Elle est falsifiable au même point : le jour où un modèle infère de façon fiable l'intention non dite, l'écart se referme.

La valeur de l'opérateur se concentre exactement là où le coût ne tombe plus. Non parce qu'il est rare comme exécutant (il ne l'est pas, il ne sait pas exécuter) mais parce que la fonction qu'il occupe est la seule dont le coût résiste à l'effondrement général. C'est aussi ce qui dicte le régime optimal de l'opérateur : disperser sa bande passante d'intention sur de la largeur superficielle la consomme sans rendement, puisque c'est la profondeur sur un objet qui exploite le résidu. La concentration n'est donc pas une préférence ; c'est l'optimum imposé par l'endroit où se loge le coût irréductible.

L'opérateur n'est pas le moins coûteux des nœuds. Il est le seul dont le coût ne baisse pas, et c'est précisément ce qui le rend non substituable.

[SEGMENT 07] Limites

Toute doctrine qui ne documente pas ses bords est une idéologie. Voici les bords. Aucun n'est corrigible par davantage de modèles, de passes ou de calcul ; tous sont antérieurs à la méthode.

Auto-référence. La seule preuve que cette instance produit de bons artefacts, ce sont ses artefacts. Le papier ne rompt pas ce cercle ; il refuse seulement de le maquiller : l'efficacité de la méthode n'est pas établie ici, seule sa structure l'est. C'est une limite réelle, et aucune quantité de modèles ou de passes ne la corrige : elle ne se lève que de l'extérieur, par la réfutation publique de [05]. Le $n = 1$, en revanche, n'est pas une limite de ce document mais le régime sous lequel il observe : il fonde l'existence de la variante solo, non sa reproductibilité, que le papier ne revendique pas (cf. [01]).

Le reste non sérialisable est une hypothèse. Tout le résidu de [04] repose sur l'existence d'une part d'intention que l'humain tient sans pouvoir l'écrire. Si cette part est illusoire (si l'opérateur croit seulement tenir plus qu'il n'a formulé), la seconde fonction détecte du bruit et le papier perd son objet. C'est posé comme hypothèse de travail réfutable, jamais comme acquis.

Parité non mesurée. La cible $F_{\text{int}} \leq \mu(B_h)$ de [02] n'est pas mesurée. Tant que le protocole (injection d'erreurs connues, comparaison à une relecture experte sur artefacts à défauts contrôlés) n'est pas exécuté, la parité avec l'expert isolé reste une cible de conception, non un résultat.

Clôture contingente. La correction n'est close que si un lectorat compétent lit effectivement. Exposé n'est pas vérifié. Un artefact que personne d'assez compétent n'audite reste en suspens épistémique pour une durée indéfinie, et ce suspens n'est pas réductible depuis l'intérieur du dispositif.

Domaine de validité. La méthode n'a de prise qu'entre deux bornes. En deçà : une matière dont l'intention est entièrement sérialisable (tâche routinière, spécifiable sans reste) rend l'opérateur redondant, faute de résidu à tenir. Au-delà : une matière qu'aucun nœud ne sait exécuter (un front formel réellement neuf) rend la délégation vide, car on ne délègue pas ce que personne ne peut faire. La méthode vit dans la bande intermédiaire : exécutable par les modèles disponibles, et d'intention non entièrement sérialisable.⁷ Hors de cette bande, elle ne s'effondre pas ; elle ne s'applique pas.

Contingence historique du résidu. C'est la limite la plus profonde. Le résidu non délégable n'est pas une propriété éternelle de l'esprit ; il est relatif à l'état présent des modèles. Le jour où un modèle infère de façon fiable l'intention non dite *et* présente une distribution d'erreur orthogonale aux autres, deux piliers de ce papier (la non-délétabilité de l'intention, la nécessité d'une sphère humaine) se réduisent ensemble. La fenêtre dans laquelle la fonction de l'opérateur est irréductible est bornée par la trajectoire de capacité des modèles, paramètre dimensionnant non modélisé ici. C'est ici que se lit la distinction posée en [04] : la régression survit à ce jour : un germe non délégué restera, par nécessité logique ; ce qui s'effondre, c'est sa *grandeur*, donc sa valeur. La nécessité logique persiste, vidée de portée. Ce papier documente une configuration datée, pas une vérité sur la cognition.

La description cognitive. Le portrait de l'opérateur (encodage massivement implicite, accès explicite étroit) est un rapport de soi, non une mesure. Il motive la grandeur du reste non sérialisable *pour cet opérateur* ; il ne la prouve pas, et ne se généralise à personne d'autre.

Ces bords ne fragilisent pas le document ; ils le datent et le délimitent. Une méthode qui sait dans quelle fenêtre elle opère est une méthode, non une prophétie. NOEMA décrit ce qui reste à l'humain tant que la machine ne sait pas encore le faire, et nomme par avance le jour où il n'en restera rien.

Ce document est daté par construction. Il fixe la structure d'un moment : assez tard pour que l'exécution soit massivement délégable, assez tôt pour que cette délégation ne soit pas encore reconnue comme une forme légitime de production intellectuelle. Sa fonction n'est pas d'annoncer ce régime, ni de prédire son adoption ; c'est d'attester qu'au moment où l'on évaluait encore selon l'ancien critère, le déplacement était déjà descriptible. Si ce régime devient un jour évident, NOEMA n'aura pas eu pour rôle de le prophétiser ; seulement de marquer qu'il était lisible avant d'être admis.

⁷La frontière de cette bande n'est ni stable ni lisse. Dell'Acqua *et al.* (2023) documentent une « frontière déchiquetée » (*jagged frontier*) des capacités des modèles, que les opérateurs eux-mêmes localisent mal : savoir où passe la bande est une compétence, non une donnée.

[ANNEXE A] Protocole de falsification

Cette annexe ne valide pas NOEMA ; elle indique comment le réfuter. Chacun des tests ci-dessous est conditionnel ; A.2 a reçu un premier pilote daté et contrôlé (annexe B), A.5 un premier pilote observationnel (annexe C) ; les trois autres ne sont pas exécutés, mais A.1 et A.3 sont déjà partiellement instrumentés par les archives des annexes B et C. Chacun décrit un dispositif de mesure et, surtout, le résultat qui invaliderait l'hypothèse correspondante. Un papier qui ne sait pas ce qui le réfuterait n'est pas falsifiable ; ce qui suit est la condition à laquelle les affirmations du corps cessent d'être « non encore réfutées » pour devenir « réfutées ».

A.1 Parité interne $F_{\text{int}} \leq \mu(B_h)$. Constituer un jeu d'artefacts à défauts contrôlés (erreurs connues injectées, de types et de gravités variés). Soumettre chaque artefact à la cascade de sphères de [02], et indépendamment à un relecteur humain expert isolé. Mesurer, pour chacun, la part d'erreurs injectées non détectées : F_{int} pour la cascade, $\mu(B_h)$ pour l'expert. *Réfutation* : si $F_{\text{int}} > \mu(B_h)$ de façon stable, la cible de conception de [02] est fautive : la cascade n'atteint pas la parité avec l'expert seul, et l'argument de fiabilité interne tombe. Le dispositif est à moitié instrumenté : le corpus à défauts contrôlés, la clé d'injection et la cascade de l'annexe B en constituent déjà le bras machine ; seul manque le bras humain expert.

A.2 Valeur de la décorrélation. Sur le même jeu de défauts, et avec une partition en sphères déclarée avant l'épreuve selon les critères de [02], comparer deux conditions à nombre de passes égal : (i) N vérifications dans une même sphère ; (ii) N vérifications réparties sur des sphères distinctes (familles, niveaux, matières de fine-tuning différents). Mesurer la masse d'erreurs survivantes dans chaque condition. *Réfutation* : si (i) et (ii) capturent un nombre d'erreurs statistiquement équivalent, alors la décorrélation n'apporte rien et c'est le *nombre*, non la diversité, qui gouverne ; le résultat central de [02] est faux. Un premier pilote de ce test, à n petit, est rapporté en annexe B.

A.3 Utilité des traces de transition. Soumettre un même corpus d'artefacts défectueux à deux groupes de relecteurs : l'un reçoit le seul artefact final, l'autre l'artefact *et* ses traces de transition ([03]). Mesurer le taux d'erreurs identifiées et leur localisation, c'est-à-dire la transition où l'erreur a été introduite. *Réfutation* : si l'accès aux traces n'améliore ni le taux de détection ni la localisation, la topologie temporelle n'a pas de valeur épistémique : elle est un coût sans gain. Le corpus requis existe : les journaux de l'annexe C fournissent des artefacts réels accompagnés de leurs traces, prêts pour les deux conditions.

A.4 Hypothèse du reste non sérialisable. Produire, à matière et difficulté comparables, deux familles d'artefacts : l'une sous *spécification déclarée exhaustive* (l'opérateur écrit une spécification qu'il tient pour complète, puis délègue ; toute réorientation ultérieure reste permise, mais doit passer intégralement par écrit et être versée à la spécification, sans détection d'écart tenue implicitement) ; l'autre sous *intention tenue implicitement* (réorientation et détection d'écart maintenues, comme en [04]). La première condition n'interdit pas l'itération ; elle interdit seulement que l'intention transite autrement que par sérialisation, de sorte que la seule variable séparant les deux familles soit le reste non sérialisé, et non la présence d'une boucle de correction. Faire évaluer en aveugle la fidélité et la qualité des deux familles. *Réfutation* : si les artefacts produits sous spécification déclarée exhaustive égalent ceux produits sous intention implicite, alors le reste non sérialisable est illusoire : la fonction de l'opérateur de [04], et avec elle l'objet du papier, s'effondre.

A.5 Garde de l'intention. Journaliser, sur une série de projets, les cas où la chaîne devient localement cohérente (chaque nœud valide sa sortie) tout en dérivant de l'intention initiale, et mesurer la fréquence à laquelle l'opérateur doit interrompre, réorienter ou invalider. Une

dérive est comptée lorsqu'un artefact intermédiaire satisfait les critères locaux de ses nœuds mais viole au moins une contrainte d'intention déclarée dans la base initiale ou dans les traces antérieures ; le critère est ainsi observable, non laissé au ressenti de l'opérateur. La portée du test doit être déclarée avec la même précision : une contrainte déclarée est sérialisée, donc vérifiable en principe par un nœud qui relit la base ; ce test ne mesure pas la seconde fonction de [04] (que seul A.4 atteint), mais la souveraineté de réaligement de [03], c'est-à-dire la capacité effective de l'opérateur à interrompre une chaîne localement cohérente. Le critère n'est observable qu'à ce prix. *Réfutation* : si la chaîne dérive contre l'intention plus souvent que l'opérateur ne la rattrape, la souveraineté de réaligement de [03] est inopérante : l'opérateur ne tient pas la fonction qu'il revendique. Un premier pilote observationnel, rapporté en annexe C, établit l'existence et le rattrapage de telles dérives sur un projet réel ; il n'en mesure pas la fréquence.

Ces cinq tests ne se renforcent pas mutuellement ; chacun vise un pilier distinct, et l'échec d'un seul suffit à réfuter la partie du papier qu'il porte. Hormis les pilotes des annexes B et C, aucun n'est exécuté ici : leur énoncé est la dette que NOEMA contracte en se disant falsifiable. Le protocole reste sobre par nécessité : un protocole de réfutation qui promettrait ses résultats serait déjà une validation déguisée, c'est-à-dire le contraire de ce que cette annexe doit être.

[ANNEXE B] Pilote daté du test A.2 (décorrélation)

Daté du 10 juin 2026. n petit, source falsifiable : corpus, clé d'injection, prompt, matrice de détection et sorties brutes archivés dans le dossier A2_dispositif accompagnant ce document, destiné au même dépôt public qu'EIDOLON. Une asymétrie d'archive est déclarée : les passes Claude, exécutées en sous-agents à contexte froid dans la session de l'opérateur, n'y figurent que par la matrice de détection, sans sorties brutes séparées. Ce pilote ne mesure pas la parité $F_{int} \leq \mu(B_h)$ de A.1, qui reste ouverte ; il porte sur la seule thèse de décorrélation de [02].

Dispositif. Six artefacts à défauts contrôlés (domaine EIDOLON : mise à jour bayésienne, porte Noisy-OR, propagation BFS de pression, lissage EMA, gain d'information, union-find pour H_0) : cinq erreurs injectées, un contrôle propre (les identifiants E01–E06 suivent les artefacts A01–A06 ; A03 étant le contrôle, il n'existe pas d'E03). La clé d'injection est tenue hors du dispositif, jamais transmise aux vérificateurs. Trois des cinq erreurs ont un *self-check non discriminant* : l'exemple chiffré de l'artefact ne les révèle pas, elles ne se voient qu'en relisant la formule ou le code. Six sphères, prompt de vérification *identique*, contexte vierge à chaque passe (*blinding*), aucun outil autorisé côté modèle : Claude (4 passes ; famille injectrice, vérifiant par sous-agents à contexte froid, sans accès à la clé), GPT 5.5 Max (4), Gemini 3.1 Pro (4), Kimi K2.6 (2, ralentissements), Sonar 2 (4), et une sphère outillée non-LLM (*sympy* et exécution réelle, re-dérivant la vérité de zéro sans lire la clé).

Erreur injectée	Claude ×4	GPT ×4	Gemini ×4	Kimi ×2	Sonar ×4	Outillée
E01 : Bayes (normalisation)	4/4	4/4	4/4	2/2	3/4	oui
E02 : Noisy-OR (complément)	4/4	4/4	4/4	2/2	4/4	oui
E04 : EMA (doc/code)	4/4	4/4	4/4	2/2	4/4	oui
E05 : info-gain (arithmétique pure)	4/4	0/4	4/4	2/2	0/4	oui
E06 : union-find (logique)	4/4	4/4	4/4	1/2	4/4	oui
A03 : contrôle propre	clean	clean	clean	clean	clean	clean

Résultat. La sphère outillée et trois des cinq familles (Claude, Gemini, Kimi) détectent les cinq erreurs. Un fait domine : **E05 est manquée à toutes les passes par deux familles distinctes**, GPT 5.5 Max (0/4) et Sonar 2 (0/4). E05 est la seule erreur *purement arithmétique*

(formule correcte, somme $0,137 + 0,332$ écrite $0,569$ au lieu de $0,469$) ; les deux familles ont validé l’artefact « CLEAN » à chacune de leurs passes. C’est une *défaillance silencieuse* au sens exact de [01] : une sortie confiante, cohérente et fausse, sans aucun signal. L’angle mort est précis (recalculer une somme isolée dans une dérivation par ailleurs correcte), stable, et partagé au-delà d’une famille : deux vérificateurs que la partition déclarée tenait pour des sphères distinctes le portent ensemble, fait compatible avec un recouvrement de corpus ou de distillation entre familles, dont la cause n’est pas testée ici. Sonar manque par ailleurs E01 à une passe sur quatre et la voit aux trois autres : un bruit de passe, non un angle mort.

Lecture selon [02], à nombre de passes égal $N = 4$. Cinq bras même-sphère étaient possibles, et tous doivent être déclarés : Claude $\times 4$, Gemini $\times 4$ et Kimi (deux passes seulement : bras non comparable à $N = 4$, déclaré pour mémoire) ne laissent survivre aucune erreur stable ; GPT $\times 4$ et Sonar $\times 4$ en laissent chacun une, E05, manquée à toutes leurs passes. Les bras croisés doivent l’être avec la même exhaustivité : à $N = 4$, les cinq combinaisons possibles de quatre familles distinctes contiennent toutes au moins une des trois familles qui détectent E05, et aucune ne laisse survivre d’erreur. Le contraste « 0 contre 1 » ne vaut donc que pour deux des cinq bras, et le lire comme un écart moyen entre conditions serait une sélection après coup. Ce que le pilote établit est existentiel, et c’est la forme exacte de la thèse de [02] : il *existe* des sphères dont la répétition ne réduit pas le plancher (l’angle mort est stable, $0/4$ deux fois), tandis que toute cascade croisant les familles le vide. La borne haute de [02] (un coût sans gain à ρ élevé) est instanciée par des cas réels, non par une moyenne. La donnée sépare aussi les deux composantes de défaillance distinguées en [02] : les échecs de Kimi sur E06 (une passe sur deux) et de Sonar sur E01 (une sur quatre) sont du bruit de passe, que la répétition résorbe ; les échecs de GPT et de Sonar sur E05 (toutes passes) sont des angles morts, que la répétition laisse intacts. Le pilote livre enfin un fait que la partition déclarée ne prévoyait pas, et qu’elle est précisément faite pour révéler : GPT et Sonar, déclarés sphères distinctes avant l’épreuve, partagent leur angle mort. La famille est un proxy imparfait de la sphère : l’intersection des zones aveugles de deux familles distinctes est ici non vide, c’est-à-dire que le plancher inter-familles F de [02] est instancié positivement, et la diversité effective se mesure, elle ne se décrète pas. Faux positifs : nuls sur les dix-huit passes (le contrôle propre n’est jamais signalé à tort).

Ce que le pilote établit, et ce qu’il n’établit pas. Il établit que le *blinding* par contexte vierge tient, qu’un angle mort stable et reproductible existe et qu’il est partagé par deux des cinq familles, et qu’à nombre de passes égal la cascade croisée vide un plancher que deux bras même-sphère laissent intact. Il n’établit pas la généralité : n petit, un seul corpus, une seule classe d’angle mort observée, Kimi limité à deux passes, et la sphère outillée n’a pas eu de résidu à réduire, le scrutin croisé l’ayant déjà vidé. Une objection symétrique doit être prise de face : E05 étant purement arithmétique, la sphère outillée la détecte trivialement, et l’on pourrait conclure que la diversité utile se réduit à l’outillage. La donnée dit l’inverse, et elle dit exactement la définition de la sphère en [02] : l’outil est ici le vérificateur le moins corrélé du dispositif parce qu’il opère à un autre niveau d’abstraction (il re-dérive au lieu de relire), mais sa couverture est construite à la main, oracle par artefact, et s’arrête au formalisable-exécutable : les dérives d’intention de l’annexe C lui sont par nature invisibles. La leçon n’est pas de remplacer les familles par l’outil ; c’est que la diversité maximale s’obtient en croisant les niveaux d’abstraction autant que les familles (la vérification outillée est elle-même documentée comme correctif des défaillances que l’auto-critique textuelle ne voit pas ; Gou *et al.* 2023). Statut épistémique, au sens même du papier : sur ce corpus, [02] *tient et n’a pas été réfuté* ; il n’est pas prouvé. Le test décisif exige un corpus calibré sur l’angle mort des sphères, dont la construction est elle-même non triviale, par la raison de [05] : une sphère ne fabrique pas aisément les erreurs qu’elle ne

voit pas. E05, injectée par la famille Claude et que Claude détecte, n'a été révélée comme angle mort que par l'entrée de sphères absentes (GPT, puis Sonar) : sans sphère extérieure, le résidu reste invisible. C'est l'argument de [05], rendu tangible par la donnée.

[ANNEXE C] Pilote observationnel du test A.5 (garde de l'intention)

Daté du 8 au 11 juin 2026. Observationnel, non contrôlé : les données sont les journaux de travail d'un projet réel, archivés avec ce document. Auto-rapporté par les agents eux-mêmes et par l'opérateur, qui est l'auteur ; aucun bras de comparaison. Ce pilote n'exécute pas le protocole A.5 complet (pas de mesure de fréquence) ; il établit des existences.

Dispositif. Deux exécutants de familles distinctes (Claude : architecture, review, documentation ; Codex : implémentation, vérification, signalement des risques techniques) co-produisent un composant logiciel de supervision pour un banc physique de spectrométrie RBS (goniomètre cinq axes, analyseur multicanal, automate programmable) : une matière à contraintes industrielles réelles, où une donnée factice est une défaillance grave. La coordination matérialise la topologie de [03] : une mémoire canonique partagée courte, des journaux append-only par agent au format des traces de transition (contexte lu, modification, justification, incertitudes, vérifications, handoff), aucun agent n'écrivant dans le journal de l'autre, et l'opérateur seul porteur de l'autorité d'arbitrage. Sur quatre jours : une quarantaine d'entrées de trace, build sans erreur ni avertissement à chaque transition consignée, harnais de tests passant de 32 à 82 cas.

Événements au sens de A.5. Trois dérives au sens strict du test (artefact satisfaisant les critères locaux de ses nœuds mais violant une contrainte d'intention déclarée) sont consignées, et les trois ont été rattrapées. (i) L'implémentation initiale du composant satisfait l'intégralité de ses critères locaux mais confine les sous-éléments dans un bloc indéplaçable, contre la contrainte déclarée de repositionnement libre ; détectée en review croisée, remontée à l'opérateur, qui arbitre un nouveau modèle et déclenche la réécriture. (ii) Le runtime provisoire écrivait des fichiers de mesure à valeurs nulles, contre la contrainte de sûreté déclarée « aucune donnée factice » ; détectée par l'audit de la sphère croisée, fermée à la racine par un verrou de simulation (aucune écriture disque sous pont simulé). (iii) Un menu contextuel promettait une configuration de liaison automate que la décision actée avait centralisée ailleurs ; détectée par l'opérateur lui-même. S'y ajoutent deux événements d'un autre type. Une dérive *ratifiée* : la chaîne a convergé vers un modèle de liaison contraire à une décision antérieure ; l'audit a exigé que le passage soit acté explicitement, et l'opérateur a ratifié la dérive comme nouvelle intention. La garde n'impose pas le retour en arrière ; elle impose que le déplacement soit vu et tranché par le porteur de l'intention. Et une correction par savoir non sérialisé : une hypothèse de nommage plausible produite par la chaîne (lettre de fichier = mode d'acquisition) était fausse au regard de la sémantique réelle du banc, que seul l'opérateur connaissait ; il l'a corrigée alors qu'aucune consigne écrite ne la contredisait.

Vérification croisée in vivo. Le même corpus documente la thèse de [02] sur des erreurs réelles, non injectées : chaque agent a produit des défaillances silencieuses au sens de [01] (build vert, tests verts, sortie plausible) que sa propre sphère n'a pas vues et que la sphère croisée a vues. Codex a relevé sur le code de Claude, entre autres : deux risques de premier rang (acquisitions concurrentes par double déclenchement ; contrôleurs runtime survivant à l'import et à l'annulation), puis cinq constats d'audit dont le verrou de simulation ci-dessus, puis une écriture critique dont le code ignorait le retour d'échec. Claude a relevé sur l'implémentation de Codex le confinement de (i), et, en phase d'audit, un défaut d'ordonnancement physique subtil :

la charge intégrée, latchée par l'automate tant que le bit de demande est haut, était lue après la retombée du bit, donc potentiellement fausse. Aucune de ces erreurs n'était détectable par les critères locaux de la sphère qui les avait produites ; toutes l'ont été par une sphère croisée ou par l'opérateur. Une collision d'édition concurrente (deux agents construisant le même fichier simultanément) a en outre été détectée par incohérence entre les traces et l'état du dépôt, puis convertie en règle de partition par zones : le coût de gouvernance de [03] n'est pas théorique.

Ce que le pilote établit, et ce qu'il n'établit pas. Il établit des existences : des dérives au sens de A.5 se produisent sur un projet réel, sont détectables, et ont toutes été rattrapées ici ; le format de trace de [03] est opérable en continu et a servi à détecter une collision ; la vérification croisée inter-familles capture in vivo des défaillances silencieuses réelles, complément naturel des erreurs injectées de l'annexe B. Il n'établit ni fréquences ni proportions : les dérives non détectées sont indénombrables par construction, l'opérateur est juge et partie, et un projet unique ne généralise rien. Le protocole A.5 complet (journalisation systématique, critère déclaré à l'avance, comptage) reste à exécuter ; ce pilote montre seulement qu'il est exécutable.

Références

- Amodei, D., Olah, C., Steinhardt, J., Christiano, P., Schulman, J. & Mané, D. (2016). Concrete Problems in AI Safety. arXiv:1606.06565.
- Bai, Y. *et al.* (2022). Constitutional AI: Harmlessness from AI Feedback. arXiv:2212.08073.
- Christiano, P., Shlegeris, B. & Amodei, D. (2018). Supervising Strong Learners by Amplifying Weak Experts. arXiv:1810.08575.
- Clark, A. & Chalmers, D. (1998). The Extended Mind. *Analysis* 58(1), 7–19.
- Condorcet, N. de (1785). *Essai sur l'application de l'analyse à la probabilité des décisions rendues à la pluralité des voix*. Paris : Imprimerie royale.
- Dell'Acqua, F. *et al.* (2023). Navigating the Jagged Technological Frontier : Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality. Harvard Business School Working Paper 24-013.
- Du, Y., Li, S., Torralba, A., Tenenbaum, J. B. & Mordatch, I. (2023). Improving Factuality and Reasoning in Language Models through Multiagent Debate. arXiv:2305.14325.
- Eckhardt, D. E. & Lee, L. D. (1985). A Theoretical Basis for the Analysis of Multiversion Software Subject to Coincident Errors. *IEEE Transactions on Software Engineering* SE-11(12), 1511–1517.
- Gou, Z. *et al.* (2023). CRITIC: Large Language Models Can Self-Correct with Tool-Interactive Critiquing. arXiv:2305.11738.
- Husserl, E. (1913). *Ideen zu einer reinen Phänomenologie und phänomenologischen Philosophie*, livre I, §§88–90 (origine du concept de *noéma*).
- Irving, G., Christiano, P. & Amodei, D. (2018). AI Safety via Debate. arXiv:1805.00899.
- Knight, J. C. & Leveson, N. G. (1986). An Experimental Evaluation of the Assumption of Independence in Multiversion Programming. *IEEE Transactions on Software Engineering* SE-12(1), 96–109.
- Lee, H. *et al.* (2023). RLAIIF vs. RLHF: Scaling Reinforcement Learning from Human Feedback with AI Feedback. arXiv:2309.00267.

- Popper, K. R. (1934). *Logik der Forschung*. Vienne : Springer ; trad. angl. *The Logic of Scientific Discovery*, Londres, Hutchinson, 1959.
- Wang, X. *et al.* (2022). Self-Consistency Improves Chain of Thought Reasoning in Language Models. arXiv:2203.11171.
- Zheng, L. *et al.* (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. arXiv:2306.05685.